



Міністерство освіти і науки України
Національний технічний університет України
“Київський політехнічний інститут імені Ігоря Сікорського”
Факультет інформатики та обчислювальної техніки
Кафедра інформаційних систем та технологій

Лабораторна робота №7

Проектування та дослідження програмних систем зі штучним інтелектом

*Тема: «Реалізація та дослідження гібридної нейронної мережі
CNN-bi-LSTM для розпізнавання мовлення в тексті»*

Виконала
студентка групи ІК-51мп:
Яковенко Д. О.

Практичне завдання.....	2
Хід роботи	3
Набір даних та підготовка.....	3
Архітектура мережі	4
1. Вхідні дані (Input & Reshape)	4
2. Згортковий блок (CNN Front-end).....	5
3. Рекурентний блок (RNN Core)	5
4. Блок класифікації (Dense Layers)	6
5. Функція втрат (CTC Loss).....	6
Тренування моделі.....	7
Тестування моделі на даних з датасету і на власних даних	9
Відповіді на питання	11
Висновки.....	12

Практичне завдання

Мета роботи: Написати програму, що реалізує нейронну мережу типу CNN-bi-LSTM для розпізнавання мови в текст. Використати набір даних LJ-Speech.

Завдання на лабораторну роботу

1. Завантажити набір даних LJ-Speech.
2. Провести попередню обробку аудіо для навчання нейронної мережі.
3. Запрограмувати архітектуру нейронної мережі DeepSpeech2.
4. Навчити нейронну мережу DeepSpeech2.
5. Провести тестування моделі – написати програму перетворення аудіо в текст навченою нейронною мережею. Провести тестування на аудіо файлах з навчального набору даних так і з аналогічними за параметрами файлами, що не входять до набору аудіо даних.
6. Додаткове завдання на +1 бал. Проаналізувати та реалізувати існуючі на сьогодні методи(функції,бібліотеки) виправлення помилок в текстах. Застосувати їх для пост обробки результатів нейронної мережі по розпізнаванню аудіо в текст, порівняти результати роботи цих методів за показником WER.

Хід роботи

Набір даних та підготовка

Для навчання моделі було використано набір даних **LJSpeech-1.1**, який містить аудіозаписи та їх текстові транскрипції.

- **Обсяг даних:** Успішно завантажено та оброблено 13 100 аудіофайлів. Дані були розділені на робочу вибірку (50% від усього датасету) та тестову. Робоча вибірка була додатково поділена на навчальну (90%) та валідаційну (10%).
- **Словник:** Створено словник із 31 символу, що включає всі літери англійського алфавіту, пробіл та базові розділові знаки ('?!).
- **Обробка аудіо:** Кожен аудіофайл був конвертований у спектрограму за допомогою віконного перетворення Фур'є (STFT) з довжиною вікна `frame_length = 256` та кроком `frame_step = 160`. Отримані спектрограми були нормалізовані (обчислення середнього та стандартного відхилення) для покращення збіжності моделі.



Рис. 1. – Обробка аудіо-файлів

Пайплайн обробки успішно генерує хвильовий графік сигналу та двовимірну спектрограму, яка використовується як вхідний тензор для нейромережі.

Архітектура мережі

Model: "DeepSpeech_2"		
Layer (type)	Output Shape	Param #
input (InputLayer)	(None, None, 193)	0
expand_dim (Reshape)	(None, None, 193, 1)	0
conv_1 (Conv2D)	(None, None, 97, 32)	2,304
conv_1_bn (BatchNormalization)	(None, None, 97, 32)	128
conv_1_relu (ReLU)	(None, None, 97, 32)	0
conv_2 (Conv2D)	(None, None, 49, 32)	90,112
conv_2_bn (BatchNormalization)	(None, None, 49, 32)	128
conv_2_relu (ReLU)	(None, None, 49, 32)	0
reshape (Reshape)	(None, None, 1568)	0
bidirectional_0 (Bidirectional)	(None, None, 1024)	6,395,904
dropout (Dropout)	(None, None, 1024)	0
bidirectional_1 (Bidirectional)	(None, None, 1024)	4,724,736
dropout_1 (Dropout)	(None, None, 1024)	0
bidirectional_2 (Bidirectional)	(None, None, 1024)	4,724,736
dropout_2 (Dropout)	(None, None, 1024)	0
bidirectional_3 (Bidirectional)	(None, None, 1024)	4,724,736
dropout_3 (Dropout)	(None, None, 1024)	0
bidirectional_4 (Bidirectional)	(None, None, 1024)	4,724,736
dense_1 (Dense)	(None, None, 1024)	1,049,600
dense_1_relu (ReLU)	(None, None, 1024)	0
dropout_4 (Dropout)	(None, None, 1024)	0
output_classifier (Dense)	(None, None, 32)	32,800
Total params: 26,469,920 (100.97 MB)		
Trainable params: 26,469,792 (100.97 MB)		
Non-trainable params: 128 (512.00 B)		

Рис. 2. – Архітектура моделі DeepSpeech_2

Ця архітектура є класичною реалізацією моделі **DeepSpeech 2**, адаптованої для задачі автоматичного розпізнавання мовлення. Вона належить до класу end-to-end (наскрізних) моделей.

Загальний розмір моделі становить **~26.4 млн параметрів**, що робить її достатньо потужною для розпізнавання мови, але при цьому відносно легкою для навчання на сучасних GPU.

Нижче наведено детальний розбір кожного компонента та обґрунтування, чому обрано саме такий підхід.

1. Вхідні дані (Input & Reshape)

- Модель приймає на вхід спектрограми аудіосигналу (з розмірністю 193 ознаки на кожному часовому кроці, як видно зі скріншота). Шар Reshape додає ще один

вимір, перетворюючи двовимірну спектрограму на «одноканальне зображення» (None, None, 193, 1).

- Це стандартний крок підготовки даних для того, щоб спектрограму можна було обробляти згортковими шарами (Conv2D), які очікують формат зображення (batch, height, width, channels).

2. Згортковий блок (CNN Front-end)

- Складається з двох шарів Conv2D з нормалізацією (BatchNormalization) та активацією ReLU.
 - Перший шар має $\text{strides}=[2, 2]$, що зменшує розмірність і по часу, і по частоті вдвічі.
 - Другий шар (як вказано у ваших коментарях до коду) має виправлений $\text{strides}=[1, 2]$. Він продовжує стискати частотну вісь, але **зберігає часову вісь**.
- **Чому обрано саме це:**
 1. **Виділення ознак:** Згорткові шари чудово знаходять локальні патерни на спектрограмах (наприклад, форманти, переходи між приголосними та голосними), працюючи як візуальний "фільтр" звуку.
 2. **Зменшення обчислень:** Зменшення частотного виміру різко скорочує кількість параметрів для наступних рекурентних шарів.
 3. **Збереження часу:** Виправлення strides на $[1, 2]$ є критично важливим. Якби часовий вимір стискався занадто сильно, модель фізично не змогла б видати достатню кількість символів для довгого тексту, що викликало б помилку в CTC Loss.

3. Рекурентний блок (RNN Core)

- Після того, як згорткові шари відпрацювали, дані "вирівнюються" (Reshape) і передаються у блок з **5 двонаправлених шарів GRU (Bidirectional)**. Кожен шар має 512 юнітів (разом 1024 для двонаправленого). Між шарами використовується Dropout (0.5).
- **Чому обрано саме це:**
 1. **Контекст часу:** Згортки бачать лише маленькі "шматочки" звуку, а рекурентні мережі (RNN) запам'ятовують послідовність. Вони розуміють, як попередні звуки впливають на поточні.
 2. **Двонаправленість (Bidirectional):** Для розпізнавання мови критично важливо знати не лише те, що було сказано *до* цього моменту, але й те, що *після*. Наприклад, закінчення слова може змінити розуміння його початку.
 3. **GRU замість LSTM:** GRU (Gated Recurrent Unit) виконує майже ті ж функції, що й LSTM, але має менше математичних операцій. Це робить навчання швидшим і споживає менше відеопам'яті без помітної втрати якості.

4. **Глибина (5 шарів):** Глибокі RNN дозволяють моделі вивчати ієрархічні ознаки мови: від базових фонем на перших шарах до цілих складів та слів на останніх.

4. Блок класифікації (Dense Layers)

- Передостанній шар Dense на 1024 нейрони з активацією ReLU та Dropout. Останній шар — це Dense з кількістю нейронів `output_dim + 1` (у вашому випадку 32) та активацією softmax.
- Останній шар видає ймовірність кожного символу вашого словника (літери + пробіл) для *кожного часового кроку*. Одиниця додається для спеціального "порожнього" (blank) токена, який необхідний для роботи CTC.

5. Функція втрат (CTC Loss)

- Спеціальна функція Connectionist Temporal Classification.
- Це серце всієї архітектури. В аудіозаписах ми знаємо текст, але не знаємо, **на якій саме секунді** вимовляється кожна літера (немає посимвольного вирівнювання). CTC Loss вирішує цю проблему: він дозволяє мережі передбачати символи з "порожніми" проміжками (наприклад, h-e---l-l--o) і математично зводить їх до фінального слова (hello). Без CTC навчити таку наскрізну модель було б неможливо.

Тренування моделі

Загальний час, витрачений на тренування моделі становить **9838 секунд**, що дорівнює **~164 хвилинам** або **2 годинам і 44 хвилинам**

Epoch 14/20	185/185	456s	2s/step	loss: 47.2258	val_loss: 53.1914
Epoch 15/20	185/185	457s	2s/step	loss: 43.8239	val_loss: 49.3416
Epoch 16/20	185/185	458s	2s/step	loss: 40.4338	val_loss: 47.2337
Epoch 17/20	185/185	477s	3s/step	loss: 37.6260	val_loss: 45.8597
Epoch 18/20	185/185	458s	2s/step	loss: 34.7032	val_loss: 45.8499
Epoch 19/20	185/185	457s	2s/step	loss: 32.4578	val_loss: 45.0042
Epoch 20/20	185/185	458s	2s/step	loss: 30.1478	val_loss: 43.2309

Рис. 3. – Тренування моделі DeepSpeech_2




Рис. 4. – Графік навчальних і валідаційних втрат

На графіку зображено дві криві: синя відповідає за втрати на тренувальних даних (Training Loss), а червона — за втрати на валідаційних даних (Validation Loss).

- Початковий етап (Епохи 1–5):** Ми бачимо дуже різке падіння обох кривих. Тренувальні втрати знизились із 304.5 до 122.0, а валідаційні — з величезних 439.8 до 102.5. Це свідчить про те, що модель дуже швидко схоплює базові патерни в аудіоданих (фонемі, паузи тощо). Цікаво, що з другої епохи валідаційні втрати навіть трохи нижчі за тренувальні — це нормальне явище, яке

часто пояснюється використанням Dropout (він вимикається під час валідації, роблячи мережу більш впевненою).

2. **Етап стабілізації (Епохи 6–15):** Криві продовжують спадати, але вже набагато повільніше. Модель переходить від вивчення базових звуків до більш складних залежностей у словах. Криві йдуть дуже щільно одна до одної.
3. **Плато (Епохи 16–20):** Графік стає майже горизонтальним. Тренувальні втрати досягають ~ 30.1 , а валідаційні ~ 43.2 . Нахил кривих стає мінімальним, що вказує на те, що модель досягла своєї оптимальної здатності до навчання при поточному кроці навчання (learning rate).

Тестування моделі на даних з датасету і на власних даних

```
1/1 ————— 1s 892ms/step
1/1 ————— 1s 608ms/step

Word Error Rate: 0.4254

Target : of this it may be said that though there is some good paper made now
Prediction: of this it may besaid that tho their is some god paper made now

Target : and that the latter is chemically speaking just as complicated as the former
Prediction: ad that the latteris cemicly speking justoce complicated as the forme

Target : moreover although it remains true that there is an inverse relation between the green plant in sunshine and the animal
Prediction: more over although it remains tre that ther risan invers relation between the green plant in sunshine and the anim

Target : the person in the window was a white man and quote looked to me like he was looking straight at the triple underpass end quote down elm street
Prediction: the person in the window was of bitman and quote looke to m alick e was looking strate at the triple underpass and quote down elm stre

Target : fauntleroy meanwhile lay in newgate not herded with other condemned prisoners as the custom was
Prediction: fautlaroy men wil lay in newgate not eard id withather condemned presoners as the custer w
```

Рис. 4. – Очікувані і отримані результати розпізнавання на даних з датасету

1. Результати на валідаційному наборі даних: Показник WER (Word Error Rate) становить **0.4254** (або 42.5%). Модель видає цілком читабельний текст, але робить фонетичні помилки. Вона навчилася розпізнавати англійську вимову специфічного диктора з датасету LJSpeech і намагається транскрибувати почуте по буквах (наприклад, "chemically" -> "cemicly", "straight" -> "strate").

```
1/1 ————— 2s 2s/step

Результат для файлу harvard.wav:
Передбачений текст: ffththuterfthd hnd eru cuirfombun dhrmun oo hurd hder upardr

▶ 0:18 ————— 0:18
```

Рис. 5. – Тестування на власних даних

2. Результати у файлі harvard.wav: Оригінальний текст: *"The stale smell of old beer lingers. It takes heat to bring out the odor..."*

Результат на власному файлі є абсолютно нечитабельним і виглядає як набір випадкових літер. Модель повністю провалила розпізнавання цього аудіо.

Чому модель видала такий поганий результат на harvard.wav?

Модель добре навчилася, але вона навчилася в дуже специфічних умовах. Ось основні причини провалу:

- 1. Один диктор у датасеті навчання:** Датасет LJSpeech складається із записів жінки, яка читає книги з дуже специфічною інтонацією, швидкістю та акцентом.
- 2. Різниця в якості та середовищі запису:** Дані з LJSpeech записані в професійній студії без фонового шуму, з використанням якісного мікрофона. Мій файл harvard.wav може мати інший рівень гучності, інші фонові шуми.

3. **Відсутність мовної моделі:** Поточна архітектура — це суто акустична модель. Вона передбачає літери лише на основі звуку. Вона не знає правил англійської граматики та не має словника існуючих слів. Сучасні системи (наприклад, Whisper) завжди використовують мовну модель, яка перевіряє: "чи існує слово, що ми отримали, в англійській мові?". Якщо ні, вона замінює його на фонетично найближче реальне слово. Без такої перевірки модель видає будь-яку комбінацію літер, що їй "почулося".

Відповіді на питання

Етапи попередньої обробки аудіо: Дискретизація (оцифрування), нормалізація гучності, видалення шуму/тиші, розбиття на фрейми (кадрування), застосування віконної функції (напр., вікно Геммінга), перетворення Фур'є (FFT), та отримання спектрограми або мел-спектрограми.

Що таке спектрограма: Це візуальне двовимірне представлення аудіосигналу (осі: час і частота, колір: амплітуда). Її використовують, бо вона перетворює звук на "картинку", дозволяючи застосовувати потужні нейромережі комп'ютерного зору (наприклад, CNN) для пошуку акустичних патернів.

MFCC vs Сирі спектрограми: MFCC — це сильно стислі ознаки, адаптовані під людське вухо, з яких видалено багато акустичних деталей. Сирі мел-спектрограми зберігають більше інформації, що дозволяє сучасним глибоким нейромережам (Deep Learning) самостійно виділяти корисні закономірності.

CNN для зображень vs для аудіо: У зображеннях осі X та Y рівнозначні (просторові). У спектрограмах осі мають різну фізичну природу (час і частота). Тому патерни в аудіо не є інваріантними до зсуву по вертикалі (зміна частоти змінює суть звуку — наприклад, голос чоловіка чи дитини), тоді як кіт на фото залишається котом незалежно від того, в якому кутку він знаходиться.

Роль RNN/LSTM/GRU: Вони мають внутрішню пам'ять і здатні зберігати контекст попередніх аудіофреймів. Це критично для мовлення, де значення поточного звуку сильно залежить від того, що було сказано до і після нього.

Attention-механізм: Це механізм, який дозволяє мережі динамічно "фокусувати увагу" на найбільш релевантних частинах аудіосигналу при генерації конкретного слова, ефективно ігноруючи шум, паузи або неважливі звуки.

Проблеми шуму: Зниження співвідношення сигнал/шум (SNR), перекриття частот корисного голосу та фонових звуків, а також реверберація (відлуння). Це спотворює спектрограму і різко знижує точність моделі.

Data augmentation для аудіо: Накладання фонового шуму, зміна швидкості відтворення (time stretching), зміна висоти тону (pitch shifting) та маскування випадкових блоків часу чи частот (SpecAugment). Це робить модель стійкішою до реальних умов.

Метрики оцінки: WER (Word Error Rate — відсоток помилково розпізнаних слів) та CER (Character Error Rate — відсоток помилок на рівні символів). Чим ці показники нижчі, тим точніша система.

Інші застосування аудіомереж: Музика (генерація, розпізнавання жанрів, поділ на інструменти), біоакустика (ідентифікація птахів чи тварин), медицина (аналіз серцебиття, виявлення хвороб за кашлем), безпека (голосова біометрія), промисловість (виявлення поломок механізмів за звуком).

DeepSpeech2 (автор і рік): Розроблена дослідницьким підрозділом компанії Baidu Research у 2015 році.

Принциповий підхід DeepSpeech2: End-to-End (від кінця до кінця). Вона напряду перетворює вхідні аудіоспектрограми у текст без використання проміжних фонемних словників або ручного конструювання ознак.

Роль CNN у DeepSpeech2: Згорткові шари (1-3 штуки) стоять на самому початку. Вони виділяють базові час-частотні ознаки зі спектрограми та зменшують розмірність даних перед подачею їх у рекурентну частину.

Роль RNN (LSTM/GRU) у DeepSpeech2: Глибокі шари (до 7) двоспрямованих RNN використовуються для моделювання довгострокових часових залежностей — вони "збирають" контекст зі всього висловлювання, обробляючи ознаки, видані CNN.

Функція втрат у DeepSpeech2: CTC (Connectionist Temporal Classification) Loss. Її використовують, бо вона дозволяє навчати мережу без необхідності точного посимвольного вирівнювання (моделі не потрібно знати, в яку конкретно мілісекунду була сказана кожна літера).

Як працює CTC: Алгоритм вводить спеціальний символ "пробілу/порожнечі" (blank). Він розраховує ймовірності для кожного кадру, а потім згортає повторювані символи та видаляє "пустушки" (наприклад, "h-e-e-[blank]-l-l-o" згортається у "hello").

Відмінність від гібридних систем: Класичні системи склалися з окремих ізольованих модулів: акустичної моделі (HMM/GMM), лексичного словника і мовної моделі. DeepSpeech2 замінює акустичне і лексичне моделювання однією нейромережею.

Апаратні ресурси: Через велику глибину мережі та складність послідовних обчислень RNN для навчання потрібні потужні кластери з десятків або сотень сучасних **GPU (графічних процесорів)** та швидкі системи зберігання для роботи з величезними датасетами.

Інтеграція мовної моделі (LM): Модель мови (зазвичай N-gram алгоритм) додається на етапі декодування результатів (за допомогою Beam Search). Вона виправляє фонетичні помилки, обираючи граматично правильні слова (наприклад, виправить акустично схоже "wreck a nice beach" на правильне "recognize speech").

Обмеження порівняно з Whisper / wav2vec 2.0: Рекурентна архітектура DeepSpeech2 обробляє дані послідовно, що повільно і важко паралелізується. Сучасні моделі на базі **Transformer** (Whisper) використовують механізм Self-Attention для миттєвого охоплення всього контексту, швидше навчаються завдяки паралелізму та (як wav2vec 2.0) можуть ефективно використовувати нерозмічені аудіодані (Self-Supervised Learning).

Висновки

У ході виконання цієї лабораторної роботи було створено та протестовано нейронну мережу для розпізнавання англomовного мовлення (Speech-to-Text) на основі архітектури, подібної до DeepSpeech 2. Робота дозволила на практиці ознайомитись із повним циклом обробки аудіоданих та тренування end-to-end акустичної моделі.